

Apuntes teorico 9/04

materia: analisis de datos

profesor: GERONIMO INES


Cosas que vamos a ver durante la clase : **etl - data warehouse - data lake**

definición de base de datos : Conjunto de datos relacionados y organizados que permite organizar los datos de forma eficiente

HERRAMIENTAS - TECNOLOGIAS / estructurada y no estructurada

Sistemas que permiten que la informacion pueda ser gestionada por personas o aplicaciones

ESTRUCTURADA: sql - my sql - oracle - postgres sql



NO ESTRUCTURADA :



COMO SE MUEVEN Y PREPARAN LOS DATOS

FUENTE de datos ---> transformacion (limpieza) ---> destino (data warehouse)

proceso para extraer, transformar y cargar (extract, transform and load)

las tecnologias, permiten procesar, analizar y modelar los datos

R--> analisis estadisticos

JULIA ---> alto rendimiento

PYTHON ---> versatil y estandar en el mercado

son mas eficientes para el analisis que los lenguajes tradicionales como c++, java, etc.

ETL

extraccion

tomamos los datos desde distintas fuentes

- bases de datos
- apis / sistemas externos
- archivos (excel, CSV)

transformar

Preparamos los datos para que tengan sentido


- limpieza
- unificacion
- validacion
- calculos

carga

guardamos los datos listos para el analisis

- data warehouse
- modelos de datos
- tablas finales

sin el ETL , los datos no son confiables ni utiles para analizar



Cómo se ve un ETL

```
CREATE PROCEDURE sp_ETL_Ventas
AS
BEGIN
    -- 1. EXTRACT (Origen) y 2. TRANSFORM (Limpieza/Cálculo)
    INSERT INTO FactVentas (FechaKey, ProductoID, Total, FechaCarga)
    SELECT
        CAST(FORMAT(Fecha, 'yyyyMMdd') AS INT), -- Transform: Formato Fecha
        ISNULL(ProductoID, 0), -- Transform: Limpieza Nulos
        (Cant * Precio) - Desc, -- Transform: Regla de Negocio
        GETDATE() -- Metadato
    FROM Staging_Ventas WHERE Procesado = 0;

    -- 3. LOAD / CIERRE (Control de flujo)
    UPDATE Staging_Ventas SET Procesado = 1 WHERE Procesado = 0;
```

ASI SE VE UN ETL

como se obtienen los datos desde el origen ?

EXTRACCION TOTAL---> trae todos los datos cada vez

INCREMENTAL---> trae solo lo nuevo o modificado

AUTOMATICA ---> el sistema avisa cuando hay cambios

CONTINUA---> flujo constante de datos en tiempo real

que buscamos ??!

convertir los datos crudos en informacion confiable y usable

ETAPAS CLAVE:

limpieza y calidad, estandarizacion, consolidación, enriquecimiento.

la CARGA:

La carga define donde, y como se almacenan los datos

no es solo guardar, implica optimizar, estructurar y preparar los datos para su uso.

en la practica la empresas automatizan este proceso mediante jobs o cadenas que se ejecutan procesos periodicos (semanal, diario, mensual, etc.)

vamos a usar o descargar luego power BI - power query ? esperar confirmacion ---

Power BI: visualización de datos | Microsoft Power Platform

Visualice cualquier dato e integre los objetos visuales en las aplicaciones que usa a diario con Power BI, una plataforma unificada de autoservicio e inteligencia...



microsoft.com

ENFOQUES DE ARQUITECTURA DE DATA WAREHOUSE

- hay una sola manera de que nuestra compañía puede acceder a los datos ?
- solo el equipo de IT debería acceder a los datos ?
- Que “autoservicio” se espera de las áreas no tecnicas ?

RESPONDER ESTO NOS va a ayudar a definir un modelo de arquitectura a la hora de implementar soluciones basadas en datos.

cómo acceder las áreas a los datos ?

MODELO 1: TRADICIONAL (IT centralizado)

EL IT controla el acceso a los datos con procesos de estructurados (etl / dw)

MODELO 2: SELF-SERVICE (negocio automatico)

usuarios acceden directamente a los datos con herramientas de BI (poweb BI / Tableau, etc)

el dato alojado en el warehouse no se modifica.

data lake

- Escalable, gobierno de datos , orquestacion, acceso agil
- SON repositorio centralizado de datos, pueden estar on-premise (servidor local) o en la nube
- permite ordenar grandes cantidades de datos

DATA SWAMP ---> data lake sin control

ETL (DATA WAREHOUSE) datos estructurados

ETL (DATA LAKE) datos en bruto

ejercitacion de clase:

revisar el documento y analizar

Iranian Transactions Dataset : trx-99

	A	B	C	D	E
1	status	time	card_type	city	amount
2	success	23:17 2025-09-08	Discover	ThRan	-5000
3	failed		MastCard	karaj	63489
4	success	07:32 2025-09-20	Visa	Isfahan	1502601
5	failed	03-00-2025 09-11	Discover	Qom	9999999999
6	success	22:27 2025-09-11	Amex	Mashhad	452545
7	Success	02:24 2025-09-04	Master Card	tehr@n	9999999999
8	fail	17:07 2025-09-30	Discover	Shiraz	1158713
9	fail	18:12 2025-09-23	Visa	Tehran	1387769
10	fail	02:54 2025-09-08	Visa	Qom	583952
11	fail	05:23 2025-09-12	MasterCard	Tabriz	1472823
12	failed	19:40 2025-09-06	VISA	Tehran	343679
13	fail	08:59 2025-09-21	MasterCard	Karaj	1768588
14	success	01:51 2025-09-11	visa	Mashhad	443463
15	failed	25:61 2025-09-11		Qom	100.50
16	fail	04:15 2025-09-24	Amex	Qom	1883871
17	FAIL	25:61 2025-09-11	Amex	Ahvaz	-5000
18	success	04:40 2025-09-06	Master-Card	THR	-5000
trx-99					



Actividad

1.

Descargar el dataset con transacciones bancarias

2.

Listar problemas del mismo

3.

Proponer transformaciones